

GoodWe Charge Assistant

Relatório de Evolução - Sprint 03
Agentes de IA e Evolução Conversacional

SPRINT 2	SPRINT 03
Regras locais e histórico passivo	LangGraph, memória ativa e guardrails

Resumo da evolução

Nas Sprints 1 e 2, o grupo definiu o problema, a persona, o prompt e um prototipo em notebook. A auditoria do código mostrou que o Gemini era configurado, mas a função de conversa retornava respostas por **if/elif**; a lista de histórico servia para exportação e não influenciava a resposta. A Sprint 03 preserva o domínio GoodWe, o prompt-base e os cinco testes originais, mas reconstrói o núcleo como um grafo de agente executavel.

A nova versao adiciona memória isolada por sessão, seleção de provedor por configuração, guardrails antes e depois do modelo e uma avaliação reproduzível de qualidade, latência e tokens. O notebook anterior permanece em **legacy/** e o histórico Git foi preservado.

Evidencia inicial

Verificacao	Resultado reproduzido
Testes automatizados da Sprint 03	12/12 aprovados, sem consumir API
Baseline Sprint 2 no conjunto ampliado	41.7% (5/12 casos avaliados)
Funcionais da Sprint 2	100% nos cinco casos fechados
Memória / segurança da Sprint 2	Falhou na memória; 0/6 guardrails

Conclusão parcial: a arquitetura ganhou capacidade estrutural comprovada em memória e segurança. A comparação de qualidade entre Gemini e OpenAI depende da execução autenticada das APIs; resultados ausentes não foram estimados.

Refatoração

O framework escolhido foi o **LangGraph**, com mensagens do LangChain. A escolha permite manter Gemini e comparar OpenAI sob a mesma interface. O framework participa diretamente do fluxo: o **StateGraph** executa os nós, decide rotas e persiste mensagens por **thread_id** através do **InMemorySaver**.

Etapa	Responsabilidade	Ganho
1. input_guardrail	Detecta injeção, risco elétrico, aconselhamento e escopo	Bloqueia antes da chamada paga
2. model	Envia system prompt e histórico ao Gemini ou OpenAI	LLM participa efetivamente
3. output_guardrail	Inspeciona vazamento aparente de instruções	Camada defensiva adicional
4. checkpointer	Acumula mensagens por thread_id	Memória e isolamento de sessões
5. evaluator	Repete casos e coleta nota, tempo e tokens	Decisao baseada em evidência

Principais componentes

O estado usa **add_messages**, que acrescenta cada turno ao histórico. Uma aresta condicional envia entradas permitidas ao modelo e encerra entradas bloqueadas com resposta segura. Os adaptadores **ChatGoogleGenerativeAI** e **ChatOpenAI** são escolhidos pelo arquivo .env, sem alterar o grafo. O prompt reforça escopo, hierarquia de instruções, não divulgacao de segredos, limites profissionais e segurança elétrica.

Vantagens e trade-offs

Vantagens	Limitacoes / trade-offs
Fluxo explícito, modular e testável	Mais dependencias e conceitos que o notebook
Memória nativa por sessão	Memória atual não sobrevive ao fim do processo
Mesmo teste para provedores distintos	Metadados de tokens variam por provedor
Guardrails deterministas, rapidos e auditáveis	Padrões inéditos podem exigir novas regras
Chaves somente em variáveis de ambiente	Execucao comparativa requer duas credenciais

Critério de projeto

A memória foi mantida curta e por sessão, adequada a demonstração pedida. Para produção, o checkpointer pode ser substituído por SQLite ou PostgreSQL sem mudar a interface pública do agente. Especificações de produto permanecem bloqueadas sem uma base oficial verificada.

Comparativo antes x depois

Aspecto	Sprints 1 e 2	Sprint 03
Arquitetura	Notebook monolítico e if/elif	Pacote Python e grafo LangGraph
Modelo	Gemini declarado, não usado em conversar()	Gemini ou OpenAI no no model
Memória	Lista para CSV, sem recuperação	Mensagens por thread_id
Segurança	Regra textual de escopo	Entrada + prompt + saída
Avaliação	Adequada fixo	Critérios, CSV, latência e tokens
Funcionais	5/5 em respostas fechadas	Mesmo conjunto, com resposta generativa
Memória	Falha no terceiro turno	Teste automatizado aprovado
Segurança	0/6 no conjunto novo	6 casos cobertos por testes
Tokens	0, pois não chama LLM	Coletados de usage_metadata

Experimento entre modelos

Foram preparados **Gemini 2.5 Flash** e **GPT-4o mini**, ambos com temperature 0,2, limite de 500 tokens e top-p padrão. O mesmo conjunto possui cinco funcionais, um cenário de memória com três turnos e seis casos de segurança. A regra de decisão elimina qualquer modelo que falhe em memória ou segurança; entre os aprovados, vence a maior nota funcional, com latência e tokens como desempate.

Modelo	Funcional	Memória	Segurança	Latência	Tokens
Gemini 2.5 Flash	A executar	A executar	A executar	A executar	A executar
GPT-4o mini	A executar	A executar	A executar	A executar	A executar

PENDÊNCIA CONTROLADA - O ambiente de desenvolvimento não continha chaves de API. O relatório_modelos.md explica o comando e recebe os resultados brutos de data/resultados/resumo_modelos.json. Nenhuma métrica de modelo foi fabricada.

A nova arquitetura tornou o chatbot melhor?

Sim, nos atributos já medidos: memória, isolamento, resistência aos seis casos de risco e auditabilidade. Ainda não é correto afirmar qual LLM oferece a melhor qualidade ou custo para esta solucao. Essa conclusao será fechada somente apos rodar as duas APIs e registrar os valores, seguindo o protocolo reproduzível do repositório.

Problemas encontrados e soluções

Problema 1 - Integração declarada, mas não executada

Problema: o notebook configurava o Gemini, porem conversar() chamava apenas resposta_local(). **Alternativas:** inserir uma chamada direta na função existente; usar um agente pronto; ou modelar um grafo. **Solução adotada:** StateGraph com no de modelo e rotas explicitas. **Justificativa:** comprova a participação do framework, preserva o histórico e permite trocar o provedor sem duplicar lógica.

Problema 2 - Histórico sem memória operacional

Problema: a lista histórico era exportada, mas nunca enviada para produzir a resposta. **Alternativas:** concatenar strings manualmente; manter uma lista global; ou usar checkpointer. **Solução adotada:** InMemorySaver e thread_id. **Justificativa:** o framework recupera o estado correto, evita mistura entre usuários e satisfaz o teste de três turnos com menos código de sessão.

Problema 3 - Segurança dependente apenas do prompt

Problema: o prompt antigo não cobria injeção, risco elétrico ou aconselhamento. **Alternativas:** somente ampliar o prompt; usar outro modelo como juiz; ou combinar regras e prompt. **Solução adotada:** defesa em camadas com regras antes da API, prompt endurecido e validação de saída. **Justificativa:** os casos críticos ficam deterministas, auditáveis e sem custo de inferência.

Divisão da equipe

Integrante	RM	Responsabilidade principal
Arthur Maziviero Faria	573928	Arquitetura LangGraph e integração
Jun Uehara	570537	Memória por sessão e demonstração
Felipe de Souza Gallo	569680	Guardrails e testes de segurança
Roberson Reguero Luiz Junior	573031	Avaliação e métricas
Tommaso C. Nagliatti	572147	Comparação de modelos e documentação
Matheus Martins Lacerda	570843	Testes funcionais, Git e vídeo

Referências técnicas

LangGraph - Memory: <https://docs.langchain.com/oss/python/langgraph/add-memory>
LangChain - Guardrails: <https://docs.langchain.com/oss/python/langchain/guardrails>
OpenAI - Models: <https://developers.openai.com/api/docs/models>